

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ «ВЫСШАЯ
ШКОЛА ЭКОНОМИКИ»**

Московский институт электроники и математики им. А.Н. Тихонова

**МОДЕЛЬ ПРОГНОЗИРОВАНИЯ СПРОСА ДЛЯ ОПТИМИЗАЦИИ ЗАПАСОВ
ТОВАРОВ**

Выпускная квалификационная работа
по направлению 01.03.04 «Прикладная математика»



Студент: Комаров Фёдор Викторович



Руководитель: доцент Внуков А.А.

Москва — 2025

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Московский институт электроники и математики им. А.Н. Тихонова

**ЗАДАНИЕ
на выпускную квалификационную работу**

Студенту Комарову Федору Викторовичу
Образовательной программы «Прикладная математика»

1. Тема работы

Модель прогнозирования спроса для оптимизации запасов товаров

2. Цель работы

Построение модели прогноза спроса для улучшения стратегии управления запасами малой торговой компании

3. Содержание работы

1. Обзор научной и прикладной литературы;
2. Предварительный анализ деятельности и сбор данных;
3. Построение моделей;
4. Анализ качества результатов;
5. Написание сравнительного анализа.

Проект ВКР представлен студентом «25» февраля 2025 г.



A.A. Внуков

Руководитель ВКР

Первый вариант ВКР представлен студентом «20» апреля 2025 г.



А.А. Внуков

Руководитель ВКР

Итоговый вариант ВКР представлен студентом «7» мая 2025 г.



А.А. Внуков

Руководитель ВКР

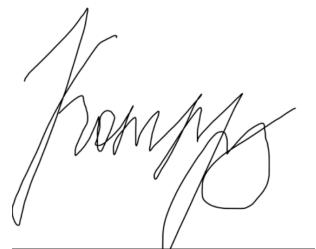
Задание выдано студенту «20» декабря 2024 г.



А.А. Внуков

Руководитель ВКР

Задание принято студентом «20» декабря 2024 г.



Ф.В. Комаров

Аннотация

Данная работа направлена на изучение проблемы оценки будущего спроса товара, что является важной частью в оптимизации системы управления запасами торгового или производственного предприятия. Объектом анализа выступает малая торговая компания, продажи которой будут прогнозироваться. В ходе данного исследования были изучены как источники, посвящённые организации закупок и запасов товаров, так и литература, посвящённая методам прогнозирования спроса. Впоследствии были разработаны три математические модели, основанные на статистических методах и современном машинном обучении. Наилучшая модель будет выбрана по оценкам выбранных метрик качества. В конце исследования будет представлена обновлённая стратегия по управлению запасами рассматриваемой торговой компании, основанная на полученной модели.

Abstract

This work is aimed at studying the problem of estimating the future demand for goods, which is an important part in optimizing the inventory management system of a trading or manufacturing enterprise. The object of analysis is a small trading company, whose sales will be forecasted. In the course of this study, both sources devoted to the organization of purchases and inventories of goods and literature devoted to the method of demand forecasting were studied. Subsequently, three mathematical models were developed based on statistical methods and modern machine learning. The best model will be selected based on the estimates of the selected quality metrics. At the end of the study, an updated inventory management strategy for the trading company in question will be presented, based on the obtained model.

Содержание

1 Введение	6
1.1 Обзор проблематики	6
1.2 Актуальность	7
1.3 Цель исследования	8
1.4 Задачи исследования	8
2 Основная часть	8
2.1 Обзор литературы	8
2.2 Предварительный анализ	10
2.3 Подготовка данных	12
3 Разработка моделей	18
3.1 Модель ARMA	19
3.1.1 Теоретические основы	19
3.1.2 Реализация модели ARMA	21
3.2 Модель LightGBM	23
3.2.1 Теоретические основы	23
3.2.2 Реализация модели LightGBM	25
3.3 Модель LSTM	27
3.3.1 Теоретические основы	27
3.3.2 Реализация модели LSTM	30
3.4 Сравнительный анализ моделей	33
4 Заключение	34
5 Список литературы	35
6 Приложения	36

1 Введение

1.1 Обзор проблематики

Система управления запасами является неотъемлемой частью любого торгового или производственного предприятия. Она отвечает за контроль объёмов выпускаемой или реализуемой продукции, а также за хранение на складе производственного сырья и готовых товаров.

Первые теоретические основы управления запасами были заложены в конце XIX — начале XX века учёными Ф. Эджуортом и Ф. Харрисом, которые предложили первую оптимизационную модель. Эта модель позволяла рассчитать экономически обоснованный объём партии поставки при условии равномерного спроса и стабильных интервалов потребления.

Современные условия характеризуются значительно более высокими темпами экономического развития по сравнению с прошлым столетием, что существенно усложняет процесс эффективного управления запасами и повышает его актуальность. Усиление конкурентной борьбы и устойчивый тренд на диверсификацию продукции обуславливают необходимость оперативного реагирования на потребительский спрос и ориентации производства на ключевые факторы: высокое качество продукции, снижение затрат, сокращение сроков поставки, ускоренное выполнение заказов и наличие необходимого количества товаров в нужный момент.

Кроме того, развитие инновационных технологий, таких как внедрение ERP-систем для отслеживания товарооборота и получения статистических данных, а также интеграция алгоритмов машинного обучения в ключевые бизнес-процессы, способствует усилинию конкурентной среды на рынке.

Учитывая вышесказанное, разработка и внедрение современных подходов к управлению запасами становится одной из приоритетных задач для эффективного функционирования торговых и производственных предприятий.

Создание модели, оптимизирующей управление запасами, позволяет минимизировать риски, связанные как с дефицитом, так и с избытком товарных остатков.

К основным рискам недостатка товара относятся:

- снижение объёма продаж и, как следствие, потери в прибыли;
- возможный отток постоянных клиентов, обращающихся к альтернативным поставщикам;
- рост логистических издержек, особенно в случаях, когда стоимость доставки превышает цену единицы товара.

Риски, связанные с избытком товара:

- возникновение просроченных товаров;
- рост операционных издержек, в том числе налогов и затрат на хранение.

Совершенствование системы управления запасами может включать:

- разработку рекомендательных систем для выявления перспективных товаров;
- оптимизацию логистических цепочек поставок;
- построение прогностических моделей для оценки будущего спроса на продукцию.

Настоящее исследование посвящено разработке прогностической модели на основе данных малой торговой компании. Предполагается, что внедрение данной модели позволит повысить эффективность стратегии управления запасами за счёт более точного прогнозирования спроса.

1.2 Актуальность

Представленные ниже основные финансовые показатели, полученные за отчетный период, отражают текущее экономическое положение рассматриваемого коммерческого предприятия.

Год	Выручка	Количество чеков	Средний чек	Себестоимость	Операционные расходы
0 2022	7186888	13266	541.75	3825258	928549
1 2023	6279355	10755	583.85	3348827	1005432
2 2024	7279134	9757	746.04	3941426	1073209

Таблица 1. Фин. показатели компании

Анализ данной таблицы позволяет установить, что общие операционные расходы, связанные с хранением остатков товарно-материальных ценностей, составляют около 20% потенциальной прибыли, рассчитываемой как разница между выручкой и себестоимостью производства. Данный факт свидетельствует о наличии избыточных закупок, что влечет за собой значительные затраты. Более того, можно обоснованно предположить, что текущая стратегия управления запасами неэффективна не только с точки зрения избыточного предложения, но и с точки зрения недостаточного объема закупок, что в конечном итоге приводит к потерям прибыли из-за неудовлетворенного спроса.

Выявленные обстоятельства подчеркивают необходимость разработки и внедрения эффективной модели прогнозирования спроса, способной обеспечить своевременную корректировку системы управления запасами.

1.3 Цель исследования

Целью данного исследования является повышение эффективности текущей системы управления запасами розничной компании. Ожидается, что это будет достигнуто путем анализа текущих недостатков, связанных с контролем поставок и запасов как для отдельных продуктов, так и для категорий продуктов. Работа включает в себя разработку модели прогноза спроса, направленную на предотвращение проблем, вызванных как чрезмерным накоплением продукции, так и ее дефицитом в момент спроса. Ожидается, что внедрение предлагаемой модели окажет положительное влияние на основные финансово-экономические показатели компании. В частности, снижение операционных расходов за счет оптимизации остатков на складе и увеличение выручки за счет минимизации потерь, связанных с отсутствием востребованных товаров.

1.4 Задачи исследования

Для достижения поставленной цели в рамках данного исследования последовательно решаются следующие задачи:

1. Провести обзор научной и прикладной литературы, посвященной методам управления запасами, в том числе современным подходам к прогнозированию потребительского спроса.
2. Провести предварительный анализ деятельности исследуемого коммерческого предприятия, включая его характеристику, а также выявление основных недостатков в существующей системе управления запасами.
3. Реализовать модели прогноза спроса, включая построение алгоритмического пайплайна для каждой архитектуры, обучение и оценку качества моделей с использованием соответствующих метрик.
4. Провести сравнительный анализ построенных моделей с целью определения лучшей из них по выбранному набору технических метрик качества.
5. Формулировка заключения, обобщающего результаты исследования и дающего интерпретацию с точки зрения поставленной цели.

2 Основная часть

2.1 Обзор литературы

В современной научной литературе, посвященной оптимизации систем управления запасами, основное внимание уделяется совершенствованию традиционных подходов, основанных на статистических моделях, путем внедрения методов регрессионного

анализа и алгоритмов машинного обучения. Особое внимание уделяется интеграции этих подходов в процессы управления продажами, контроля запасов и определения точек повторного заказа.

Так, в работе Сарит Майтра, Вивека Мишроя и Сукани Кунду[1] рассматриваются динамические изменения спроса на ассортиментную матрицу продукции. Предложенный методологический подход основан на применении метода Монте-Карло для генерации выборок на основе эмпирических или априорных распределений. Далее используется гауссова регрессия, базирующаяся на многомерном нормальном распределении, для оценки параметров в пространстве (r, q) , где r — момент перезаказа, q — объём заказа. Ковариационная структура между точками определяется с использованием квадратичного экспоненциального ядра.

Л. Беттчер, Т. Асикис и И. Фрагкос[2], а также М. Пирхуссаран и Л. В. Снайдер[3] исследуют эффективность различных архитектур нейронных сетей при прогнозировании оптимального объёма заказов в дискретные временные интервалы. Сравнительный анализ демонстрирует, что рекуррентные нейронные сети (RNN) и глубокие нейронные сети (DNN) обладают повышенной чувствительностью к колебаниям спроса, особенно в условиях сезонности и во время праздничных периодов, по сравнению со стандартными регрессионными моделями и моделями градиентного бустинга. Вместе с тем, в периоды низкой волатильности точность прогноза, измеряемая с использованием метрик MSE и MAPE, остаётся сопоставимой для всех подходов.

Инженеры по машинному обучению из крупной российской торговой компании X5 Retail Group также делятся прикладным опытом решения задачи прогнозирования спроса в работе Валерия Бабушкина "Прогнозирование спроса в X5 Retail Group"[4]. В качестве базовых алгоритмов используются CatBoost, LightGBM и XGBoost, реализующие метод градиентного бустинга. Выбор данных моделей обоснован особенностями структуры входных признаков, формируемых в рамках data-driven подхода. Источниками информации выступают как внешние данные (например, прогноз погоды, уровень осадков), так и внутренние — данные о продажах в B2B и B2C сегментах.

В процессе исследования были также проанализированы публикации, посвящённые вопросам повышения эффективности стратегии продаж и правильной обработки истории транзакций. В частности, в статье "Как подготовить историю продаж, чтобы получить корректный прогноз спроса"[5] рассматриваются распространенные статистические проблемы, такие как дефицит продукции, влияние акций и скидок, сезонные колебания, выбросы и последствия, а также методы их правильного учета в моделях прогнозирования.

Кроме того, в исследовании "Cross-selling и Upselling: что это такое и как применить в интернет-магазине"[6] анализируются две популярные стратегии управления продажами, которые способствуют росту ключевых финансовых показателей компании. Перекрестные продажи подразумевают предложение покупателю сопутствующих товаров,

которые дополняют его выбор. В свою очередь, апдейл направлен на стимулирование покупки более дорогих или улучшенных версий продукции.

Таким образом, анализ научных и прикладных источников подтверждает важность интеграции современных методов анализа данных в процессы управления запасами и продажами, что обосновывает разработку прогностической модели в рамках данного исследования.

2.2 Предварительный анализ

Объектом исследования является торговое предприятие, осуществляющее свою деятельность на территории Московской области с 2019 года. Виды экономической деятельности компании классифицируются по следующим кодам ОКВЭД: 47.25 (основной вид деятельности) — торговля розничная напитками в специализированных магазинах и 47.11 — торговля розничная преимущественно пищевыми продуктами, включая напитки, и табачными изделиями в неспециализированных магазинах.

Предприятие относится к категории микропредприятий в соответствии с Федеральным законом № 209-ФЗ. Основными критериями отнесения к данной категории являются: численность работников до 15 человек, доля участия иных юридических лиц в уставном капитале менее 25%, годовая выручка не более 120 млн рублей. Предприятие применяет упрощенную систему налогообложения (УСН, объект налогообложения – доход) с момента постановки на учет в Федеральной налоговой службе.

Штатная структура компании включает:

- Кассир (работа по графику 5/2, полная ставка, заработка плата — 50 тысяч рублей до вычета НДФЛ);
- Кассир (работа по графику 5/2, полная ставка, заработка плата — 50 тысяч рублей до вычета НДФЛ);
- Владелец компании, совмещающий функции генерального директора (работа на полной ставке; уровень заработной платы не раскрывается).

Процесс управления закупками имеет древовидную структуру.

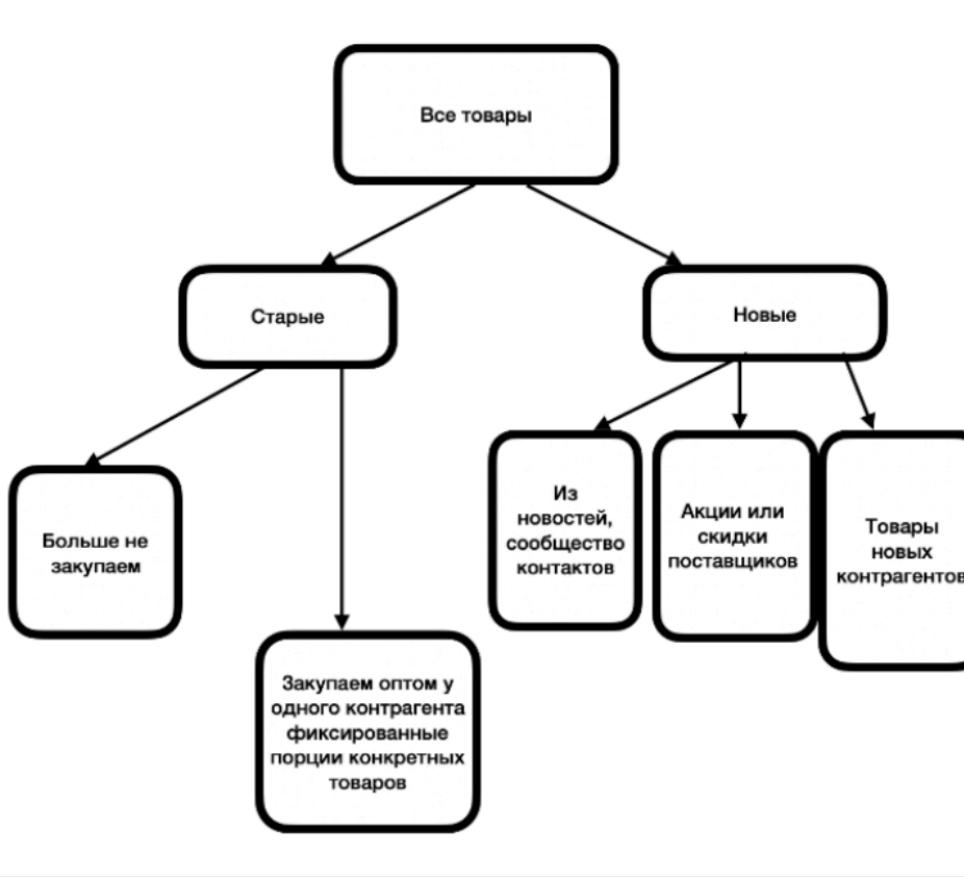


Рисунок 1. Древовидная структура управления запасами компании

В её основе лежит распределение всех товаров на две группы: "новые" и "старые".

К категории "новых" товаров относятся те позиции, которые были приобретены владельцем на основании следующих факторов:

- наличие акций у действующих поставщиков;
- специальные предложения от новых поставщиков;
- высокая популярность товара в профильных сообществах.

Для "старых" товаров решение о необходимости покупки принимается на основе анализа интервала продаж и текущего остатка. Если товар подлежит закупке, применяется стратегия ожидания, при которой заказ товара осуществляется только после достижения нулевого или близкого к нулевому баланса как минимум по трем товарным позициям у поставщика.

Этот подход чем-то напоминает модель точки повторного заказа (ROP-Q), где условием нового заказа является достижение определенного минимального уровня запасов. В рассматриваемой компании условием является нулевой запас по трем и более позициям.

Данная стратегия направлена на оптимизацию расходов на доставку и получение дополнительных скидок или бонусов от поставщиков. Однако на практике возникают ситуации, когда один из основных приносящих доход товаров заканчивается раньше, чем

будет накоплено необходимое количество товаров для оптовой закупки. В этих случаях компания допускает отклонения от базовой стратегии, размещая заказ на одно-два изделия, не дожидаясь сборки всей партии. Также стоит отметить, что ERP-приложение «Мой склад» используется для управления процессами закупок, предоставляя функции оповещения, когда остаток товара падает ниже установленного порогового значения или достигает его. Если автоматические уведомления игнорируются, пользователь может вручную контролировать остатки на складе с помощью системы фильтров. Анализ существующей модели управления запасами выявил следующие основные недостатки:

- отсутствие оперативной оценки упущенной прибыли вследствие отсутствия товара на складе при ожидании условий для оптовой закупки;
- увеличение товарных остатков и потери прибыли, вызванные неточным определением оптимального количества закупаемой продукции.

Иллюстрация проявления указанных недостатков представлена в приложении 1.

Выявленные проблемы подчёркивают актуальность разработки эффективной модели прогнозирования спроса, что подтверждает значимость проводимого исследования.

2.3 Подготовка данных

Изначально выгруженные данные представляют из себя три колонки:

	Код	Время	Кол-во
1	3333333334190	03/08/2024 20:27:00	1.0
2	3333333334190	16/07/2024 14:50:00	1.0
3	3333333334190	12/07/2024 19:02:00	1.0
4	3333333334191	19/07/2024 16:46:00	1.0
5	3333333334201	04/11/2024 14:43:00	1.0
...
39819	3333333333991	11/05/2023 22:34:00	2.0
39820	3333333333991	05/05/2023 22:25:00	1.0
39821	3333333333991	01/05/2023 22:09:00	2.0
39822	3333333333991	29/04/2023 16:48:00	2.0
39823	3333333333991	21/04/2023 22:20:00	1.0

39823 rows × 3 columns

Таблица 2. Изначальные данные

Далее перименуем колонки для удобства:

- calendar_dt(время) — дата совершения продажи;
- counts(кол-во) — количество проданных единиц товара;
- sku(код) — идентификационный код продаваемого товара (SKU).

Рассматриваемый период охватывает данные с 1 января 2023 года по 1 января 2025 года. Выбор начального порогового значения обусловлен необходимостью исключения искажений, связанных с последствиями пандемии COVID-19 и введенными в связи с ней карантинными ограничениями, которые оказали существенное влияние на поведение потребителей. Окончательный лимит установлен на начало 2025 года, поскольку на момент проведения исследования первый квартал отчетного года еще не завершился.

Для отбора продуктов, представляющих больший аналитический интерес, предлагается использовать метод ABC-XYZ. Данный подход основан на двухуровневой классификации товарных позиций по объему выручки и степени устойчивости спроса:

- **Определение.** ABC-классификация — группировка товаров по доле участия в квартальной выручке:
 - класс **A** — товары, на которые приходится около 70% совокупной выручки;
 - класс **B** — товары с долей около 20%;
 - класс **C** — оставшиеся 10% ассортимента.
- **Определение.** XYZ-классификация — сегментация на основе оценки коэффициента вариации спроса по кварталам:
 - **X** — товары с коэффициентом вариации менее 0,1 (высокая стабильность спроса);
 - **Y** — от 0,1 до 0,25 (умеренная стабильность);
 - **Z** — более 0,25 (высокая волатильность).

Пример реализации данного метода в приложении2.

В рамках настоящего исследования выбор был ограничен сегментом **AZ**, то есть товарами с наибольшим вкладом в выручку и высокой нестабильностью спроса. Такой выбор позволяет сосредоточиться на наименованиях, критически важных для прибыли компании, но при этом труднопрогнозируемых.

Ниже представлена итоговая таблица товарных позиций, входивших в кластер **AZ** на протяжении всех восьми кварталов рассматриваемого периода.

	sku	AZ(1, 2023)	AZ(2, 2023)	AZ(3, 2023)	AZ(4, 2023)	AZ(1, 2024)	AZ(2, 2024)	AZ(3, 2024)	AZ(4, 2024)
0	03	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
1	14	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
2	25	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
13	333333333754	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
15	333333333773	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
21	3333333333917	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
27	54	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0

Рисунок 2. Отобранные товары категории AZ все 8 кварталов

Ниже представлены динамике каждого товара:

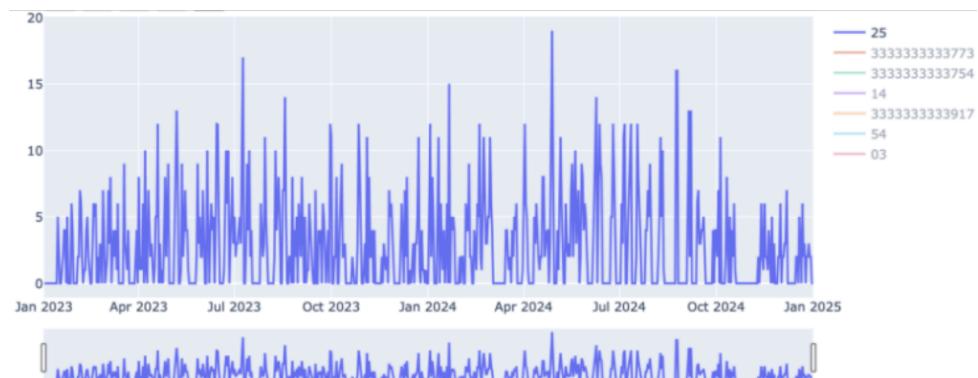


Рисунок 3. Динамика товара 25

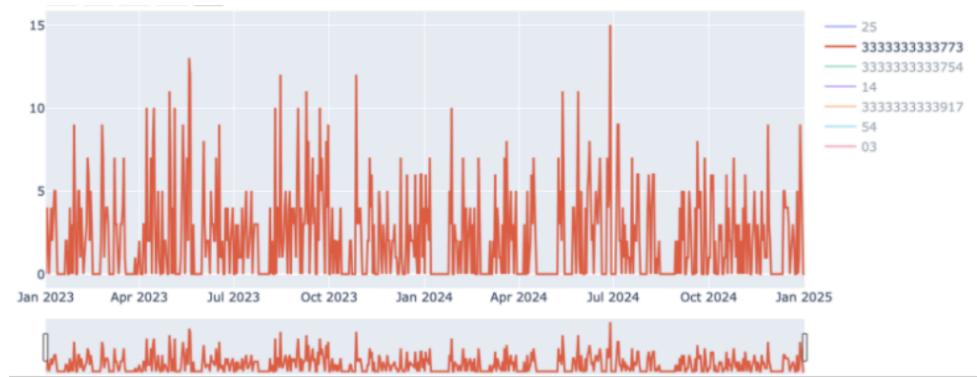


Рисунок 4. Динамика товара 333333333773

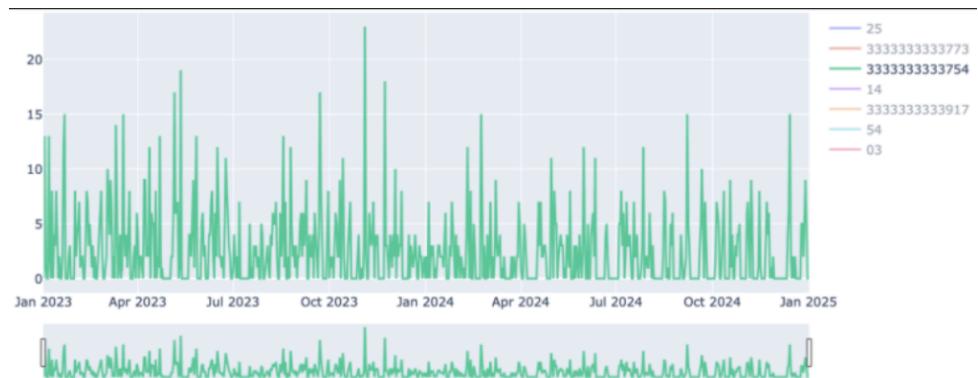


Рисунок 5. Динамика товара 333333333754

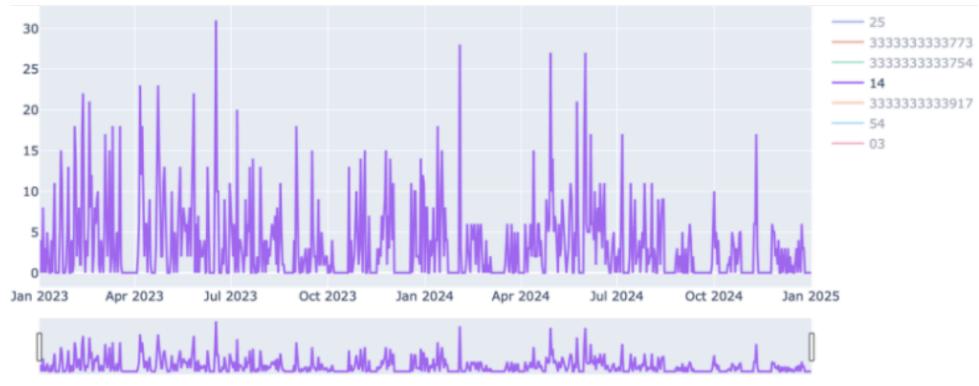


Рисунок 6. Динамика товара 14

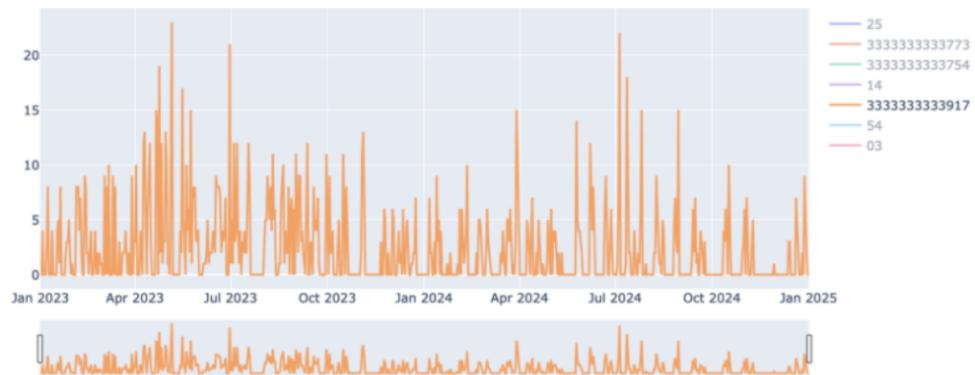


Рисунок 7. Динамика товара 3333333333917

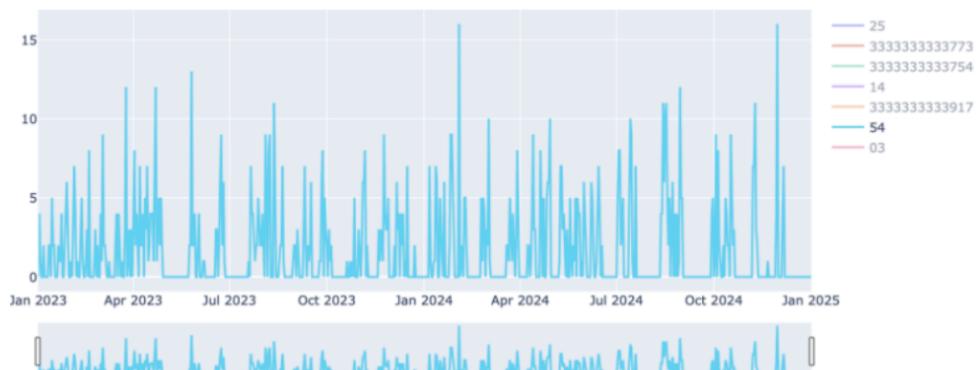


Рисунок 8. Динамика товара 54

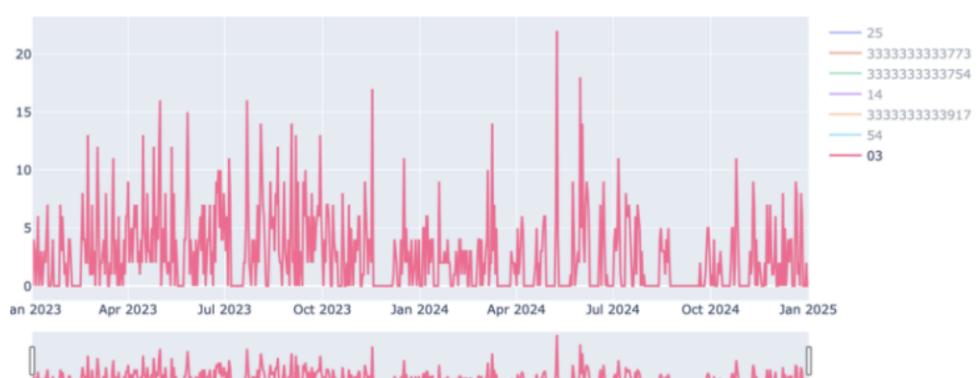


Рисунок 9. Динамика товара 03

Также в приложение 3 представлена тепловая карта по товарам для обнаружения сезонности.

На каждом из представленных выше рисунков можно проследить наличие ряда проблем, среди которых наиболее заметны случаи *out-of-stock* (отсутствия товара в наличии). Кроме того, возможно наличие эффекта пост-реализации, возникающего после возобновления продаж отдельных товарных позиций.

Следует отметить, что в масштабах исследуемой компании практически отсутствуют признаки сезонности, а также не проводятся акции и скидочные кампании ввиду ограниченных финансовых возможностей компании.

Явление *out-of-stock* представляет собой одну из наиболее серьёзных проблем при анализе продаж товаров. В исследовании были проанализированы все периоды, характеризующиеся длительными интервалами нулевых продаж. По каждому из этих периодов остатки на складах проверялись и сравнивались с данными о поставках, осуществленных после окончания периода отсутствия товара в обороте.

Результаты анализа представлены в приложении 4.

Распространенные методы устранения проблемы (*out-of-stock*) включают удаление соответствующих периодов из выборки и сглаживание данных с использованием скользящего среднего или медианы. Однако в контексте данного исследования, учитывая известный характер возникновения данной проблемы, предлагается альтернативный подход.

Вместо прогнозирования продаж конкретных товаров, осуществляется моделирование спроса на уровне товарных категорий, каждая из которых включает в себя группу взаимозаменяемых (субSTITУTНЫХ) товаров. Такой переход позволяет компенсировать влияние временного отсутствия отдельных позиций, поскольку категория сохраняет обобщенный объем спроса за счет наличия аналогичных товаров.

Продажи по категориям рассчитываются как совокупная сумма продаж по нескольким SKU, отнесенным к соответствующей категории. Классификация основана на статистических данных, полученных из ERP-системы «Мой склад», используемой в торговом компании.

Предлагаемый подход позволяет устраниТЬ искажения, вызванные пропусками в данных о конкретных товарах, и тем самым повысить устойчивость прогнозной модели.

Ниже представлена таблица соответствия товарных позиций и их категорий:

sku	category
03	1
14	1
25	1
3333333333754	2
3333333333773	2
3333333333917	3
54	2

Таблица 3. Соотношение товара и категории

Было решено взять три товара первой категории для упрощения. Далее представлен график динамики продаж рассматриваемой категории.

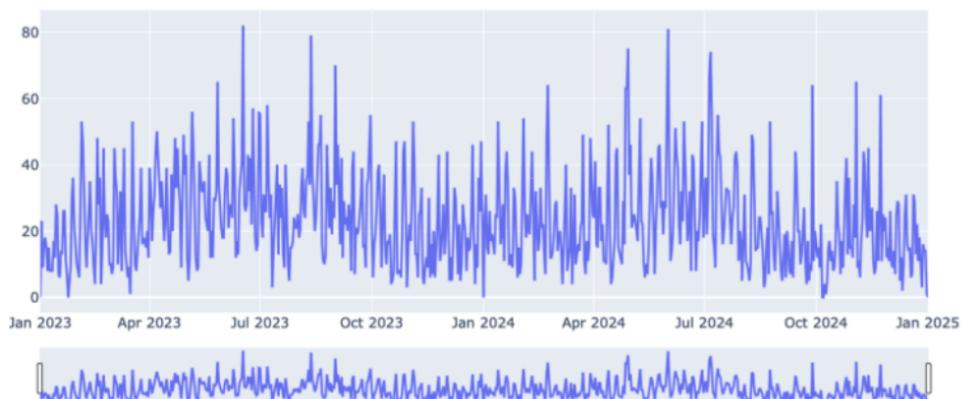


Рисунок 10. график динамики продаж первой категории

3 Разработка моделей

Для построения прогнозных моделей необходимо предварительно определить структуру выборок, а также метрики оценки качества.

В рамках настоящего исследования в качестве обучающей выборки (*train*) используется временной горизонт с начала первого квартала 2023 года по конец третьего квартала 2024 года включительно. Тестовая выборка (*test*) охватывает первые пять календарных дней четвёртого квартала 2024 года. Отложенная выборка для дополнительной проверки модели (*backtest*) включает оставшийся период четвёртого квартала 2024 года.

Прогнозирование осуществляется на один день, что обусловлено малым значением *lead-time* поставок — время доставки продукции составляет, в среднем, около восьми часов. В качестве основных метрик оценки качества прогнозов выбраны:

- средняя абсолютная ошибка (MAE, Mean Absolute Error),
- взвешенная средняя абсолютная процентная ошибка (WMAPE, Weighted Mean Absolute Percentage Error).

Данные метрики считаются лучшими практиками в маркетплейсах, потому что они удобны для бизнес интерпретации: если $wmape=15\%$, это значит что прогноз отклоняется на 15 процентов и если $mae=10$, то прогноз отклоняется на 10 единиц товара. Был проведен статистический тест Дики-Фуллера для определения наличия стационарности временного ряда. Соответствующие результаты тестирования приведены ниже:

**ADF Statistic: -3.1868477245859244
p-value: 0.020758718794769877
Ряд стационарен (отвергаем нулевую гипотезу).**

Рисунок 11. Результат теста Дики-Фуллера

Основная идея метода заключается в проверке временного ряда на наличие свойств стационарности.

Определение. Временной ряд называется стационарным, если его математическое ожидание и дисперсия являются постоянными во времени, а автокорреляционная функция зависит только от лага, но не от конкретного момента времени.

Тест Дики — Фуллера проверяет нулевую гипотезу о наличии единичного корня в модели, то есть о том, что коэффициент при предыдущем значении наблюдений равен единице. Это интерпретируется как отсутствие зависимости текущего значения ряда от его предыдущих значений: наблюдения описываются исключительно белым шумом и,

возможно, добавочной константой. В рамках данного исследования используется расширенная версия теста Дики — Фуллера, которая реализована в языке программирования Python и учитывает автокорреляцию остатков.

Формальное представление модели:

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \varepsilon_t,$$

где:

- y_t — наблюдаемое значение временного ряда в момент времени t ;
- $\Delta y_t = y_t - y_{t-1}$ — первая разность ряда (используется для устранения тренда);
- α — свободный член (константа), отражающий постоянный уровень ряда;
- βt — линейный тренд (опциональный элемент модели);
- γ — коэффициент при лагированном уровне y_{t-1} ;
- δ_i — коэффициенты при i -той лагированной разности Δy_{t-i} , учитывают автокорреляцию;
- p — количество лагов, включаемое в модель для устранения автокорреляции остатков;
- ε_t — ошибка (остаточный шум), предполагается белым шумом: $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$.

Стоит отметить, что тест представляет из себя линейное уравнение, коэффициенты которого легко находятся с помощью метода наименьших квадратов.

3.1 Модель ARMA

3.1.1. Теоретические основы

Модель ARMA (AutoRegressive Moving Average) является одной из классических моделей прогнозирования стационарных временных рядов. Он объединяет компоненты авторегрессии (AR) и скользящего среднего (MA), учитывая как зависимость текущего значения от предыдущих наблюдений, так и влияние случайного шума в предыдущие периоды.

Ниже представлено общее математическое представление модели ARMA:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j},$$

где:

- y_t — наблюдаемое значение временного ряда в момент времени t ;
- c — константа (интерцепт), отражающая средний уровень ряда;
- ϕ_i — коэффициенты авторегрессии (AR), отражающие зависимость от предыдущих значений y_{t-i} ;
- p — порядок авторегрессионной части (AR);
- ε_t — белый шум (случайная ошибка в момент времени t);
- θ_j — коэффициенты скользящего среднего (MA), отражающие зависимость от предыдущих ошибок ε_{t-j} ;
- q — порядок части скользящего среднего (MA);
- Предполагается, что $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ — нормально распределён и некоррелирован во времени (белый шум).

Также приведем один шаг алгоритма поиска вышеуказанных коэффициентов, который состоит из следующих действий:

1.Начальная инициализация.

2.Вычисление белого шума(для каждого момента времени).

$$\varepsilon_t = y_t - c - \sum_{i=1}^p \phi_i y_{t-i} - \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

3.Вычисление логарифма функции правдоподобия.

$$\log \mathcal{L} = -\frac{T}{2} \log(2\pi) - \frac{T}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{t=p+1}^T \varepsilon_t^2$$

4.Обновление параметров с использованием численных методов

На этапе начальной инициализации параметры авторегрессионной части модели (AR) могут быть определены методом наименьших квадратов или инициализированы случайным образом — как правило, в пределах модуля, меньшего единицы, чтобы обеспечить устойчивость модели. Параметры, относящиеся к компоненте скользящего среднего (MA), инициализируются случайными значениями из интервала $(0, 1)$.

В качестве первого значения случайной ошибки ε_0 принято использовать значение ноль, а дисперсию изначально принимают равной единице. После этого последовательно вычисляются значения остаточных ошибок и логарифма функции правдоподобия. Далее применяется один из численных методов оптимизации, таких как алгоритм BFGS (Broyden–Fletcher–Goldfarb–Shanno), для обновления параметров модели с целью максимизации логарифма функции правдоподобия.

Следует также отметить, что порядок модели (т. е. количество коэффициентов в частях AR(p) и MA(q)) в программной реализации Python может быть автоматически выбран на основе критерия сложности информации Акаике (AIC). Данный критерий позволяет одновременно учитывать точность модели и степень ее сложности, что способствует выбору структуры с минимальным числом параметров и достаточным качеством аппроксимации данных.

Формальное выражение критерия AIC представлено ниже:

$$AIC = 2k - 2 \ln(\hat{\mathcal{L}})$$

где:

- k — количество параметров в модели. Для модели ARMA(p, q) это:

$$k = p + q + 1,$$

где:

- p — число коэффициентов авторегрессии ϕ_i ;
- q — число коэффициентов скользящего среднего θ_j ;
- $+1$ — добавляется за константу c .
- $\hat{\mathcal{L}}$ — значение максимальной функции правдоподобия при оптимальных параметрах модели.

При полном переборе на сетке (p, q) будет выбираться пара с наименьшим значением AIC.

3.1.2. Реализация модели ARMA

Для построения модели была использована функция `auto_arima` из библиотеки `pmdarima` в языке программирования Python. С целью получения модели ARMA (без интеграционной компоненты) параметр дифференцирования был установлен равным нулю: $d = 0$. Для исключения сезонной составляющей были заданы параметры `seasonal = False` и `m = 0`, что позволяет отключить сезонность и обнулить её период.

В качестве стратегии подбора параметров модели был реализован перебор по сетке $(p, q) \in \{0, \dots, 10\} \times \{0, \dots, 10\}$. Кроме того, для повышения устойчивости модели и минимизации влияния начальных аномальных значений было произведено дополнительное сэмплирование — данные были обрезаны, начиная с 190-го дня наблюдений.

По результатам тестирования на контрольной выборке наилучшие показатели продемонстрировала модель ARMA с параметрами ($p = 7, q = 5$).

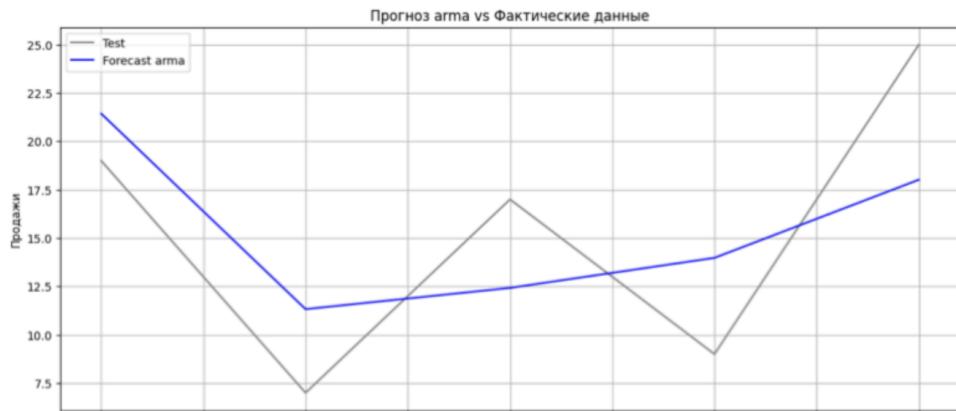


Рисунок 12. График динамики продаж не в тесте с реальными и прогнозируемыми наблюдениями

=====
 =====
MAE (средняя абсолютная ошибка): 4.66
WMAPE (взвешенная процентная ошибка): 30.18%
 =====

Рисунок 13. Метрики качества на тесте

Для получения прогноза на бэк teste был реализован подход онлайн-обучения с использованием скользящего окна. Суть метода заключается в последовательном обновлении обучающей выборки с целью включения в нее новых релевантных данных по мере их поступления. Дополнительно была предусмотрена возможность смещения окна на объём новых наблюдений, что позволяет сохранять стабильную размерность.



Рисунок 14. График динамики продаж в бэк teste с реальными и прогнозируемыми наблюдениями

=====
 =====
MAE (средняя абсолютная ошибка): 8.40
WMAPE (взвешенная процентная ошибка): 39.29%
 =====

Рисунок 15. Метрики качества на бэк teste

Анализ результатов показал, что построенная модель демонстрирует низкую чувствительность к резким изменениям данных: она сглаживает реальные колебания спроса и неточно воспроизводит пиковые значения.

Значение метрики WMAPE составляет около 40%, что не может считаться удовлетворительным уровнем точности для целей внедрения модели в реальные бизнес-процессы. Кроме того, средняя абсолютная ошибка (МЕЕ) указывает на то, что каждый последующий прогноз может иметь погрешность в среднем более восьми единиц. Это составляет примерно треть от типичного размера закупаемой партии, что делает модель непригодной для использования в деятельности компании.

3.2 Модель LightGBM

3.2.1. Теоретические основы

LightGBM является одной из наиболее широко используемых реализаций градиентного бустинга и входит в число трёх самых популярных библиотек данного класса в языке Python наряду с XGBoost и CatBoost.

Определение. Градиентный бустинг представляет собой ансамблевый метод машинного обучения, при котором последовательность слабых моделей (как правило, решающих деревьев) обучается таким образом, чтобы каждая последующая модель минимизировала ошибку предсказания предыдущей. Обновление модели происходит на основе направления антиградиента выбранной функции потерь.

В случае использования функции потерь в виде среднеквадратичной ошибки (MSE), градиентный шаг принимает следующий вид:

$$F_M(x) = F_0(x) + \nu \sum_{m=1}^M h_m(x)$$

где:

- $F_M(x)$ Конечный ансамбль после M добавлений слабых моделей.
- $F_0(x) = 1N \sum_{i=1}^N y_i$ Стартовая модель — среднее значение целевой переменной (оптимум функции потерь MSE без использования признаков).
- $h_m(x)$ m -е слабое дерево, обученное на аппроксимацию остатков r_{im} .
- $r_{im} = y_i - F_{m-1}(x_i)$ Остатки. Для квадратичной функции потерь (MSE) совпадают с $-\partial\mathcal{L}/\partial F$ — отрицательным градиентом текущего прогноза.

- $\nu \in (0, 1]$ Коэффициент обучения (learning rate), определяет длину шага; отдельного коэффициента γ_m не используется, шаг «поглощён» в ν .
- M Общее число итераций, то есть количество добавленных слабых моделей (глубина ансамбля).

Одной из ключевых архитектурных особенностей LightGBM является стратегия роста дерева по принципу *Leaf-wise*. В отличие от классического подхода, при котором дерево растёт по уровням (каждый уровень расширяется путём разбиения всех текущих листьев на основании наиболее информативных признаков), *Leaf-wise* рост осуществляется путём выбора только одного листа с наибольшим информативным приростом. Такой подход приводит к формированию *асимметричных бинарных деревьев*.

Пример подобного разбиения представлен ниже:

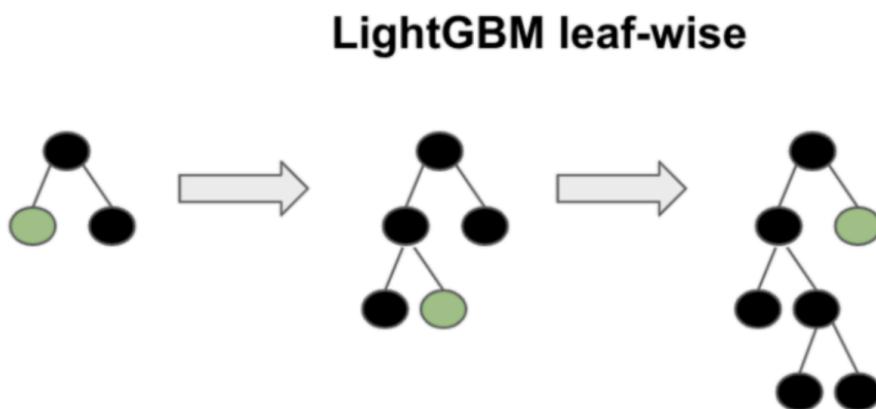


Рисунок 16. Демонстрация подхода leaf-wise

Дополнительным преимуществом LightGBM являются встроенные методы оптимизации программного обеспечения, которые значительно ускоряют обучение модели без существенной потери качества.

Одним из таких подходов является метод разделения на основе гистограмм HBS(Histogram-based Splits). Он предполагает предварительное дискретизированное представление признаков: все значения признаков группируются в фиксированное количество бинов (по умолчанию 255), после чего дальнейшая обработка производится не по исходным значениям, а по интервалам, что существенно снижает вычислительные затраты.

Другим важным методом является сжатие признаков с использованием метода FBS (Feature Bundling Compression). Он используется в случаях, когда имеются взаимоисключающие признаки, и позволяет объединить их в один компактный признак. Это, в свою очередь, помогает уменьшить размерность пространства признаков и ускорить обучение модели.

3.2.2. Реализация модели LightGBM

В рамках построения модели были сгенерированы дополнительные признаки на основе данных о продажах. В качестве временных признаков использовались лаги с шагами 1, 2, 3, 7 и 14 дней, а также скользящие статистики: средние, медианы, стандартные отклонения, экспоненциальные скользящие средние и суммы по окнам длиной 3, 7, 14 и 30 дней.

Кроме того, были сформированы признаки, отражающие тенденции: разности между лагами (например, разность между лагами 1 и 7, 1 и 14, 7 и 14), а также разность между скользящими средними длиной 7 и 14 дней. Для учета сезонности и календарных эффектов использовались следующие признаки: номер недели в году, месяц, индикаторы выходных и праздничных дней (на основе библиотеки `holidays` с поддержкой официальных праздников России), а также категория времени года.

После формирования обучающей выборки для задачи регрессионного градиентного бустинга масштабирование признаков не производилось, так как алгоритмы семейства градиентного бустинга не чувствительны к различию масштабов входных данных.

По результатам перебора гиперпараметров наилучшие показатели качества продемонстрировала модель со следующими параметрами:

- `n_estimators = 1000,`
- `max_depth = 8,`
- `lambda_12 = 1,`
- `learning_rate = 0.01.`

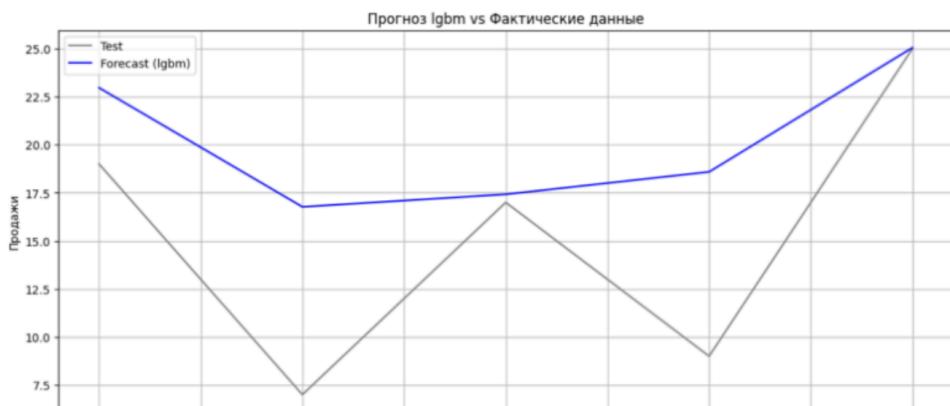


Рисунок 17. График динамики продаж не тесте с реальными и прогнозируемыми наблюдениями

=====
=====
MAE (средняя абсолютная ошибка): 4.76
WMAPE (взвешенная процентная ошибка): 30.90%
=====

Рисунок 18. Метрики качества на тесте

На следующем этапе было принято решение о расширении набора признаков. Для этого был разработан парсер архива погодных данных, с помощью которого были получены значения максимальной и минимальной температуры, а также количество осадков. Рассматривалась возможность включения в модель признаков, связанных с ценой, таких как общая сумма продаж, а также признаков, отражающих количество проданных единиц конкретных товаров и их складские остатки. Однако было принято решение отказаться от их использования, поскольку в случае изменения стратегии продаж их распределение по кварталам может существенно измениться, что приведёт к снижению репрезентативности обучающей выборки и ухудшению качества прогноза.

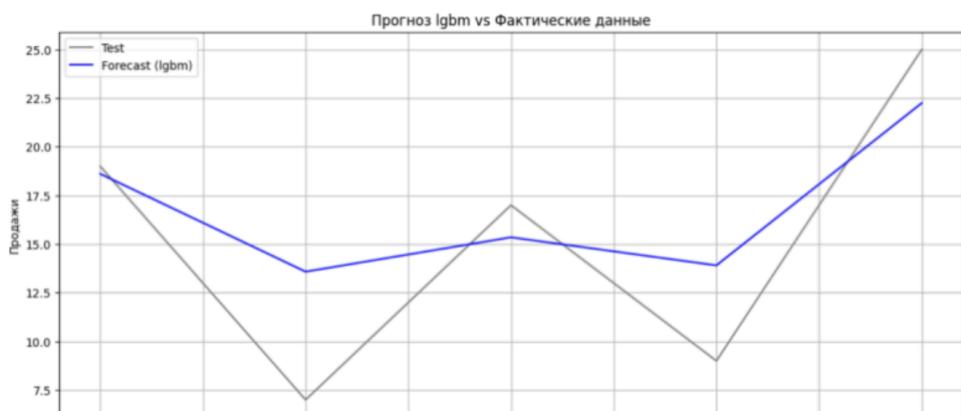


Рисунок 19. График динамики продаж на тесте с реальными и новыми прогнозируемыми наблюдениями

=====
=====
MAE (средняя абсолютная ошибка): 3.26
WMAPE (взвешенная процентная ошибка): 21.14%
=====

Рисунок 20. Метрики качества на тесте



Рисунок 21. График динамики продаж на тесте с реальными и новыми прогнозируемыми наблюдениями

```
=====
=====  
MAE (средняя абсолютная ошибка): 9.36  
WMAPE (взвешенная процентная ошибка): 48.76%
=====
```

Рисунок 22. Метрики качества на бэкстесте

Несмотря на удовлетворительные значения метрик качества на тестовой выборке, результаты на бэктестовой выборке оказались не пригодными для продуктивизации. Градиентный бустинг продемонстрировал ограниченные возможности в адаптации к резким дневным колебаниям спроса, что выразилось на метриках качества.

3.3 Модель LSTM

3.3.1. Теоретические основы

LSTM (Long Short-Term Memory) представляет собой тип рекуррентной нейронной сети (RNN), специально разработанный для эффективного хранения долгосрочной зависимости в последовательностях и решения проблемы затухающего градиента, возникающей при обучении классических RNN.

Архитектура LSTM широко применяется в различных задачах обработки естественного языка (NLP), таких как анализ последовательностей кадров, классификация текста и звука. Кроме того, данная архитектура получила широкое распространение в задачах прогнозирования временных рядов.

Процесс предсказания в рекуррентных нейронных сетях осуществляется различными способами в зависимости от типа задачи:

- в задачах регрессии используется линейный слой, применяемый к последнему скрытому состоянию;
- в задачах бинарной классификации используется сигмоидальная функция активации;
- в задачах многоклассовой классификации применяется функция активации softmax.

Основным отличием LSTM от классической RNN является добавление специализированного блока управления памятью — LSTM-блока, который позволяет более эффективно контролировать сохранение и забывание информации.

Ниже представлена схема стандартной рекуррентной нейронной сети с типом связи "один к одному", где h_t обозначает скрытое состояние, аккумулирующее информацию о предыдущих моментах времени.

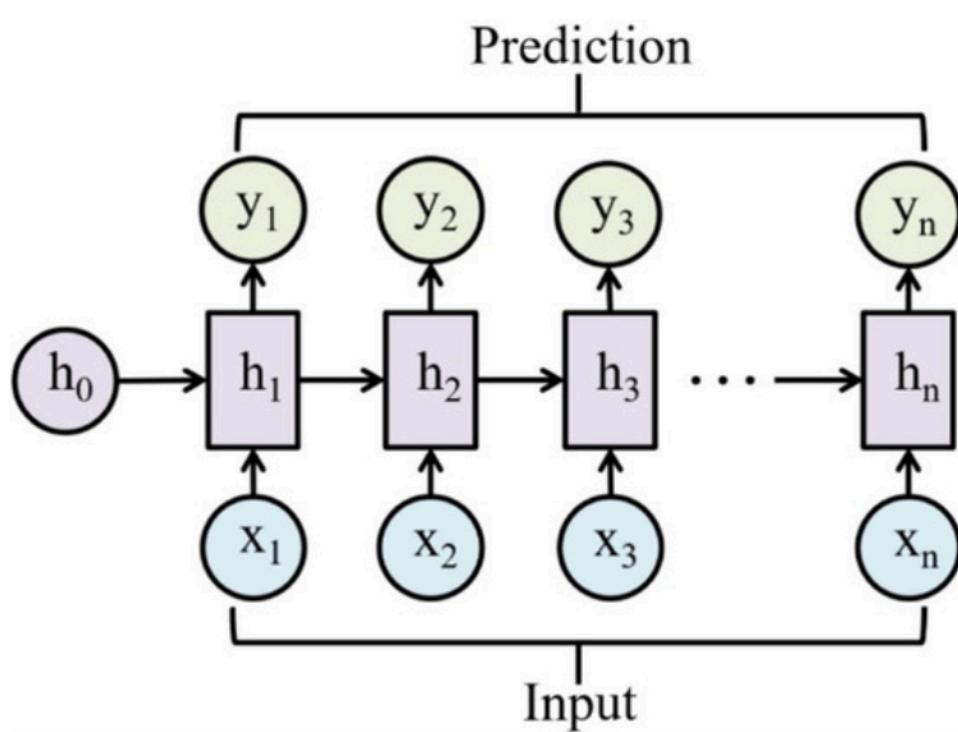


Рисунок 23. визуализация RNN

Пояснительные формулы

$$h_t = \sigma_h(W_{hh}h_{t-1} + W_{xh}x_t + b_h),$$

$$y_t = W_{hy}h_t + b_y,$$

где:

- h_t — скрытое состояние в момент времени t , агрегирующее информацию о предыдущих состояниях;
- y_t — выходное значение на шаге t (например, регрессионный прогноз или результат классификации);
- x_t — входной вектор на момент времени t ;
- W_{xh} — матрица весов между входом и скрытым состоянием;
- W_{hh} — матрица весов между скрытыми состояниями на последовательных шагах времени;
- W_{hy} — матрица весов между скрытым состоянием и выходным слоем;
- b_h, b_y — смещения (bias terms) для скрытого и выходного слоёв соответственно;
- σ_h — функция активации скрытого состояния, обычно нелинейная (например, tanh или ReLU).

Ниже представлен LSTM блок

LSTM Architecture

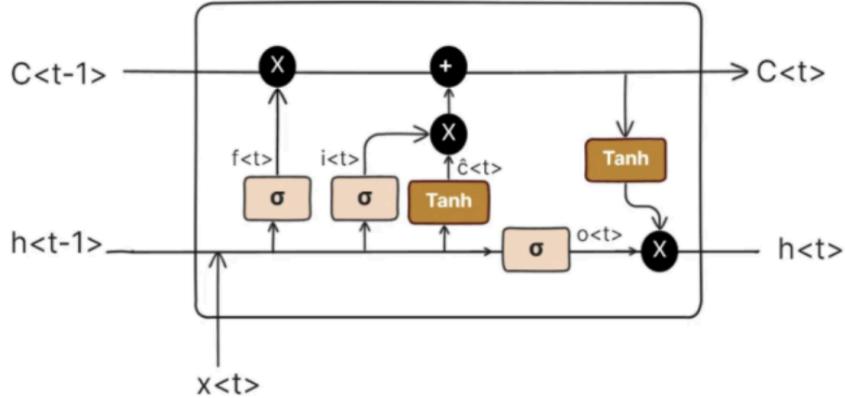


Рисунок 24. Блок LSTM

Пояснительные формулы

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f),$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i),$$

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c),$$

$$c_t = f_t * c_{t-1} + i_t * \tilde{c}_t,$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o),$$

$$h_t = o_t * \tanh(c_t),$$

где:

- c_t — вектор состояния памяти сети, аккумулирующий «важную» информацию на каждом шаге t и обновляемый на основе информации, поступающей с предыдущего шага $t - 1$.
- f_t — вектор забывания (forget gate), элементы которого принимают значения в диапазоне от 0 до 1. Он определяет, какая часть информации из предыдущего состояния c_{t-1} будет сохранена, а какая — забыта.
- i_t — вектор входного фильтра (input gate), значения которого также лежат в интервале от 0 до 1. Он определяет, какая новая информация будет добавлена в состояние памяти c_t на текущем шаге.
- \tilde{c}_t — вектор кандидатов на обновление состояния. Эти значения проходят фильтрацию через i_t перед добавлением в основное состояние памяти c_t .

- o_t — вектор выхода (output gate), контролирующий, какая часть информации из обновлённого состояния будет передана на выход и использована для формирования скрытого состояния h_t .
- h_t — скрытое состояние на шаге t , аналогичное скрытому состоянию в стандартной RNN. Оно вычисляется как результат применения функции гиперболического тангенса к состоянию памяти c_t , масштабированного выходным вектором o_t . Данная операция позволяет отфильтровать информацию, которая на текущем этапе может быть нерелевантной или даже вводящей в заблуждение.

Такой механизм особенно важен в задачах, где контекст играет существенную роль, например, в задачах классификации настроения текста, где одно и то же словосочетание может иметь различный смысл в зависимости от окружающего контекста.

Ниже представлен градиент RNN(пример для 3 скрытых состояний)

$$\frac{\partial L}{\partial h^3} \frac{\partial h^3}{\partial W} + \frac{\partial L}{\partial h^3} \frac{\partial h^3}{\partial h^2} \frac{\partial h^2}{\partial W} + \frac{\partial L}{\partial h^3} \frac{\partial h^3}{\partial h^2} \frac{\partial h^2}{\partial h^1} \frac{\partial h^1}{\partial W}$$

В классических рекуррентных нейронных сетях (RNN) при вычислении градиентов на этапе обратного распространения ошибки через время в последних слагаемых возникает громоздкое произведение множителей, отражающих зависимость скрытых состояний друг от друга. Эти множители включают в себя производные функций активации, таких как гиперболический тангенс, значения которых лежат в интервале от 0 до 1.

В результате многократного умножения этих значений происходит экспоненциальное уменьшение градиента. Это приводит к тому, что удаленные наблюдения оказываются крайне слабое влияние на обновления параметров, что ограничивает способность модели запоминать долгосрочные зависимости; возникает так называемая *проблема кратковременной памяти*.

В архитектуре LSTM эта проблема частично решается специальной структурой передачи информации через вектор состояния памяти c_t . Ключевую роль в этом процессе играет вектор забывания f_t , элементы которого при значении, близком к единице, обеспечивают приблизительное равенство $c_t \approx c_{t-1}$. В этом случае градиент фактически "проходит" через множество временных шагов без существенного затухания.

Таким образом, механизм управления памятью в LSTM позволяет существенно ослабить эффект исчезающего градиента и дает сети возможность хранить информацию в течение более длительных интервалов времени.

3.3.2. Реализация модели LSTM

Наилучшие результаты в рамках применения архитектуры LSTM были достигнуты при использовании подхода с разбиением временного ряда на интервалы длиной в

5 дней, каждый из которых подавался на вход одному блоку LSTM. Размерность скрытого состояния была установлена равной 32. Для повышения обобщающей способности модели использовалась маска Dropout, случайным образом зануляющая 10% элементов предыдущего скрытого состояния h_{t-1} .

Обучение модели проводилось в течение 300 эпох с использованием значения (learning rate) равного 0,0005. Перед началом обучения все генераторы случайных чисел, используемые в фреймворке PyTorch, были зафиксированы, что необходимо для обеспечения воспроизводимости результатов, так как начальные веса в нейронных сетях инициализируются случайным образом.

Следует также отметить, что нейронные сети чувствительны к масштабу входных данных, поэтому перед обучением был применён метод минимакс-нормализации (MinMaxScaler), преобразующий значения признаков в диапазон [0, 1] по формуле:

$$x_{scaled} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Дополнительно был реализован подход *fine-tuning*, заключающийся в дообучении предварительно обученной модели на новых поступающих данных. Суть метода заключается в активации режима обучения при появлении новых наблюдений: модель выполняет один и шаг градиентного спуска, в результате чего обновляются значения весов.

Такой механизм позволяет адаптировать модель к изменяющимся условиям и сохранять высокую точность прогнозов за счёт регулярного учёта актуальной информации.



Рисунок 25. График динамики продаж не тесте с реальными и прогнозируемыми наблюдениями

```
=====
=====  

MAE (средняя абсолютная ошибка): 7.18  

WMAPE (взвешенная процентная ошибка): 35.74%
=====
```

Рисунок 26. Метрики качества на тесте

Следует также отметить, что для согласованности масштабов был применён дополнительный этап масштабирования прогнозных значений методом MinMax-преобразования с интервалом $[0, x_{max}]$, где x_{max} — максимальное значение объёма продаж за соответствующий квартал предыдущего года. Кроме того, с целью синхронизации прогнозов с исходными временными метками был выполнен сдвиг предсказаний на один шаг влево по временной оси.

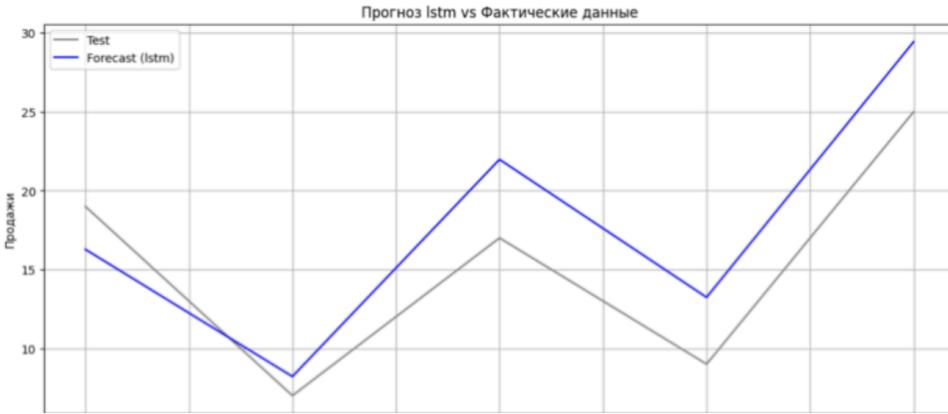


Рисунок 27. График динамики продаж не тесте с реальными и новыми прогнозируемыми наблюдениями

```
=====
=====  

MAE (средняя абсолютная ошибка): 3.52  

WMAPE (взвешенная процентная ошибка): 19.73%  

=====
```

Рисунок 28. Метрики качества на тесте

Как можно заметить, получилось существенно улучшить метрики по средствам простых преобразований: масштабирования и сдвига.



Рисунок 27. График динамики продаж не бэк teste с реальными и новыми прогнозируемыми наблюдениями

```
=====
=====  
MAE (средняя абсолютная ошибка): 3.37  
WMAPE (взвешенная процентная ошибка): 16.43%
=====
```

Рисунок 28. Метрики качества на бэк teste

Таким образом, рекуррентная нейронная сеть продемонстрировала высокую точность прогнозирования. На бэк teste значения метрик качества составили: WMAPE — 16%, MAE — 3,37.

Данная архитектура показала повышенную чувствительность к краткосрочным колебаниям спроса и способность эффективно обучаться на основе динамики дневных продаж, что делает её особенно подходящей для задач бизнеса.

3.4 Сравнительный анализ моделей

На основании полученных результатов можно заключить, что наиболее эффективной моделью для решения поставленной задачи является рекуррентная нейронная сеть типа LSTM. Значение метрики WMAPE на уровне около 15% соответствует отраслевым стандартам в сфере e-commerce и торговых компаний.

Кроме того, достигнутые показатели качества существенно превосходят аналогичные результаты, продемонстрированные моделями ARMA и LightGBM. Проведённые дополнительные эксперименты, включающие удаление верхних и нижних 1%, 3% и 5% выбросов, а также различные методы масштабирования признаков (MinMax-масштабирование, стандартное нормирование, логарифмическое преобразование), не привели к значимому улучшению качества прогнозов для моделей LightGBM и ARMA.

Следует отметить, что указанные модели (ARMA и LightGBM) имеют ограниченные возможности в корректном отражении резких колебаний спроса: их прогнозы характеризуются избыточной сглаженностью и неспособностью захватывать локальные изменения динамики дневных продаж.

Вместе с тем необходимо учитывать, что исследуемое предприятие в силу ограниченности ресурсов не располагает дополнительной внешней информацией для возможности построения признаков, отражающих внешние факторы, не связанные напрямую с внутренней торговой стратегией компании.

4 Заключение

В рамках данного исследования была реализована задача прогнозирования спроса на группу взаимозаменяемых товаров (субститутов) с использованием трёх различных моделей: ARMA, LightGBM и LSTM.

Наилучшие результаты были продемонстрированы моделью рекуррентной нейронной сети с механизмом долгосрочной памяти (LSTM). По итогам тестирования на четвёртом квартале достигнуты следующие показатели качества: WMAPE = 16% и MAE=3.37.

Внедрение данной модели в операционную деятельность предприятия позволяет существенно оптимизировать процесс управления запасами. Поскольку время доставки товаров (*lead-time*) составляет всего 8 часов, появляется возможность организовать прогнозирование спроса на следующий день и осуществлять поставку продукции в ночное время. Это открывает перспективу полного отказа от необходимости содержания складских запасов.

Следует также отметить, что расходы на одну поставку составляют около 10% от недельных операционных издержек при хранении единицы любого из субститутных товаров. Таким образом, переход на реактивную модель управления закупками позволит значительно сократить операционные расходы.

Дополнительно, применение стратегии *upselling*, ориентированной на увеличение продаж более маржинальных товаров, способно обеспечить рост прибыли на 15% по итогам четвёртого квартала, заменив продажи субститутов продажами более маржинальных товаров ,например 03.

В целом, разработанная модель прогнозирования спроса по категориям субститутов позволила сформировать стратегию, направленную на полное сокращение операционных издержек и на увеличение выручки за счёт приоритизации продаж высокомаржинальных товаров.

5 Список литературы

- [1]Sarit Maitra, Vivek Mishra, Sukanya Kundu. A Novel Approach with Monte-Carlo Simulation and Hybrid Optimization Approach for Inventory Management with Stochastic Demand. (2023)
URL:<https://arxiv.org/abs/2310.01079>
- [2]L. Böttcher, T. Asikis, I. Fragkos. Control of Dual-Sourcing Inventory Systems Using Recurrent Neural Networks. (2023)
URL:<https://arxiv.org/abs/2201.06126>
- [3]M. Pirhooshyaran, L. V. Snyder. Simultaneous Decision Making for Stochastic Multi-echelon Inventory Optimization with Deep Neural Networks as Decision Makers. (2020)
URL:<https://arxiv.org/abs/2006.05608>
- [4]Валерий Бабушкин. Прогнозирование спроса в X5 Retail Group.(2020)
URL:https://300.ya.ru/v_jHCvckj3
- [5]Как подготовить историю продаж, чтобы получить корректный прогноз спроса/[Интернет источник]Forecast-NOW(15.01.2024)
URL:<https://fnow.ru/articles/clearing-sales-history>
- [6]Cross-selling и Upselling: Что это такое и как применить в интернет-магазине?/[Интернет источник]Shop-manager(01.09.2023)
URL:<https://www.shopmanager.by/blog/2023/09/cross-selling-and-upselling/>
Данный интернет источник работает с использованием VPN.

6 Приложения

Приложение 1:

Код	Продажи			Рентабел...		
	Количество	Цена	Себестоимость	Сумма	Товара	Прибыль
3333333334208	183,5	202,07	107,30	37 080,00	88,32%	17 390,00
	183,5			37 080,00	88,32%	17 390,00

Приложение 1.1. Финансовые показатели по товару(примеру)



Приложение 1.2. Выделенный период с нулевыми продажами товара

Приемка № 01734 от 14.01.2025 19:27 Статус: Проверено

*Организация: [REDACTED] *Склад: Основной склад
*Контрагент: [REDACTED] Договор:
Баланс (если должны):
Проект: Входящий номер: от

Позиции Связанные документы Файлы Задачи Проверить комплектацию Импортировать Добавить из справочника

Все (8) Расценить Сохранить цены Скидка НДС Настройки контроллеров

Назначение	Серия	Маркировка	Принято	Остаток	Объем	Цена	Сроки	Сумма	Себестоимость	РНПТ
1 3333333333396 [REDACTED]	...		30	0	0	70,00	0%	2 100,00	2 100,00	
2 3333333333426 [REDACTED]	...		30	2	0	94,00	0%	2 820,00	2 820,00	
3 24762 [REDACTED]	...		2	1,115	0	650,00	0%	1 300,00	1 300,00	
4 3333333333427 [REDACTED]	...		30	0	0	55,00	0%	1 650,00	1 650,00	
5 3333333333428 [REDACTED]	...		24	0	0	170,00	0%	4 080,00	4 080,00	
6 3333333333417 [REDACTED]	...		6	0	0	56,00	0%	336,00	336,00	
7 3333333333418 [REDACTED]	...		6	0	0	59,00	0%	354,00	354,00	
8 3333333333419 [REDACTED]	...		6	0	0	60,00	0%	360,00	360,00	

Приложение 1.3. Приемка контрагента на 14 января, где отсутствует заданный выше товар

На дату	<input type="text" value="14.01.2025 00:00"/>	Остаток
		Любой
Только с ожиданием		Показывает
<input type="checkbox"/> Нет		<input type="checkbox"/> Только о
<input checked="" type="checkbox"/> Поставщик		<input checked="" type="checkbox"/> Годен д
		<input type="text"/>
<input checked="" type="checkbox"/> Цвет горячей кнопки		

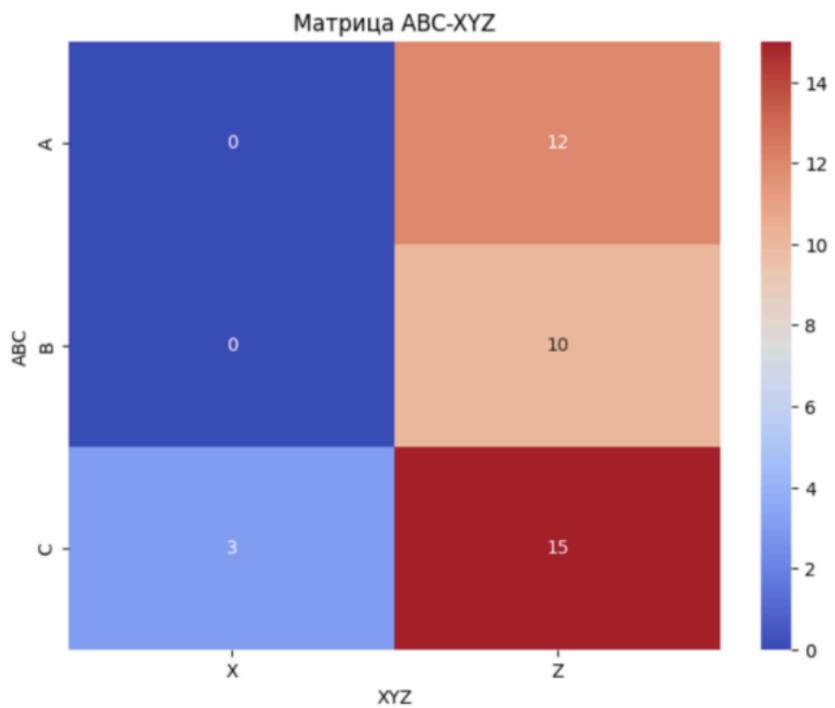
Код	Остаток	Неснижаемый остаток
3333333334	0,5	10
	0,5	

Приложение 1.4. Остаток на 14 января заданного товара

Приемка № 01739 от 18.01.2025 15:44	Статус	<input checked="" type="checkbox"/> Проведено																														
*Организация	*Склад	Основной склад																														
*Контрагент	Договор																															
Проект	Входящий номер	от																														
<input type="checkbox"/> Позиции <input type="checkbox"/> Связанные документы <input type="checkbox"/> Файлы <input type="checkbox"/> Задачи																																
<input type="checkbox"/> Все (2) <input type="checkbox"/> Расценить <input type="checkbox"/> Сохранить цены <input type="checkbox"/> Скидка																																
<input type="checkbox"/> Проверить комплектацию <input type="checkbox"/> Импортировать <input type="checkbox"/> Добавить из справочника																																
<input type="checkbox"/> НДС <input type="checkbox"/> Настроить колонки																																
<table border="1"> <thead> <tr> <th>Номенклатура</th> <th>Серия</th> <th>Маркировка</th> <th>Принято</th> <th>Остаток</th> <th>Объем</th> <th>Цена</th> <th>Сумма</th> <th>Себестоимость</th> <th>РНПТ</th> </tr> </thead> <tbody> <tr> <td>1 333333334206</td> <td></td> <td></td> <td>30</td> <td>0,5</td> <td>0</td> <td>110,00</td> <td>0%</td> <td>3 300,00</td> <td>3 300,00</td> </tr> <tr> <td>2 333333334294</td> <td></td> <td></td> <td>30</td> <td>0</td> <td>0</td> <td>55,00</td> <td>0%</td> <td>1 650,00</td> <td>1 650,00</td> </tr> </tbody> </table>			Номенклатура	Серия	Маркировка	Принято	Остаток	Объем	Цена	Сумма	Себестоимость	РНПТ	1 333333334206			30	0,5	0	110,00	0%	3 300,00	3 300,00	2 333333334294			30	0	0	55,00	0%	1 650,00	1 650,00
Номенклатура	Серия	Маркировка	Принято	Остаток	Объем	Цена	Сумма	Себестоимость	РНПТ																							
1 333333334206			30	0,5	0	110,00	0%	3 300,00	3 300,00																							
2 333333334294			30	0	0	55,00	0%	1 650,00	1 650,00																							
<input type="button" value="Добавить позицию — введите наименование, код, штранкод или в..."/>																																

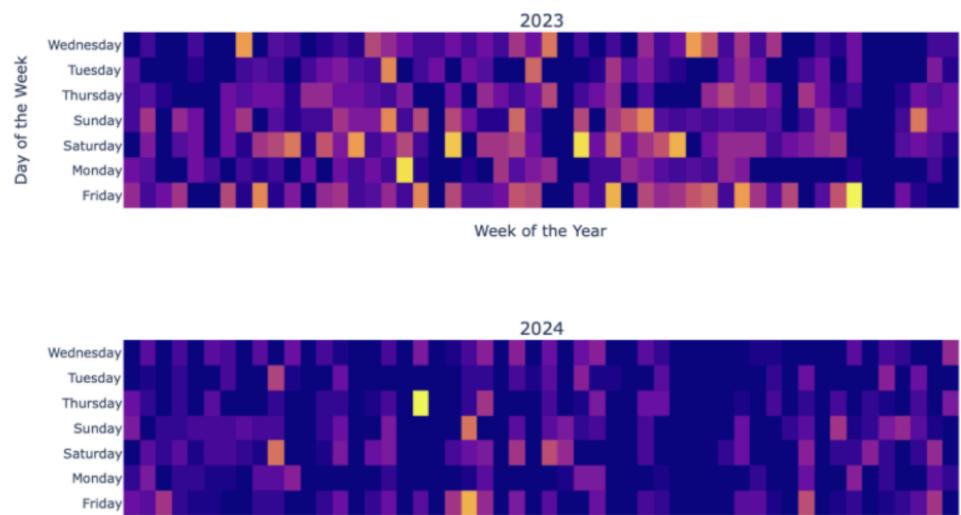
Приложение 1.5. Приемка заданного товара через 4 дня после начала его отсутствия.

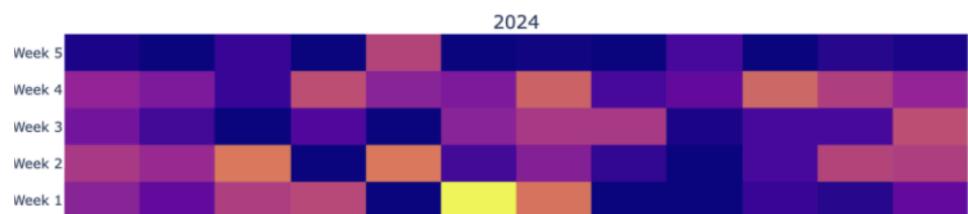
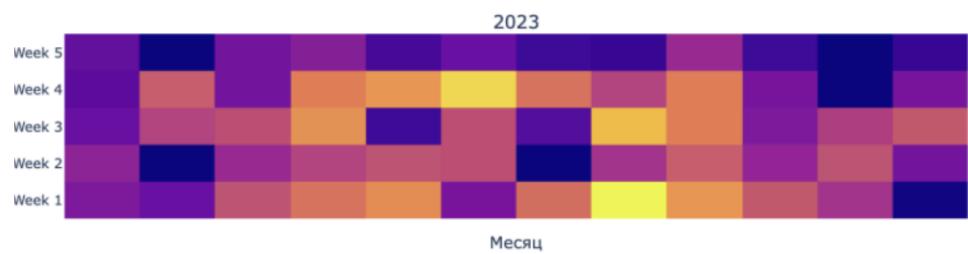
Приложение 2:



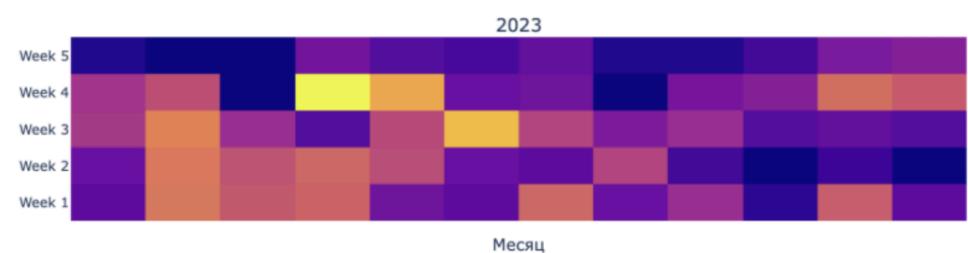
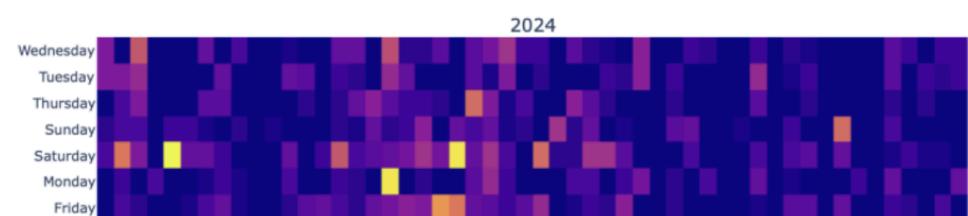
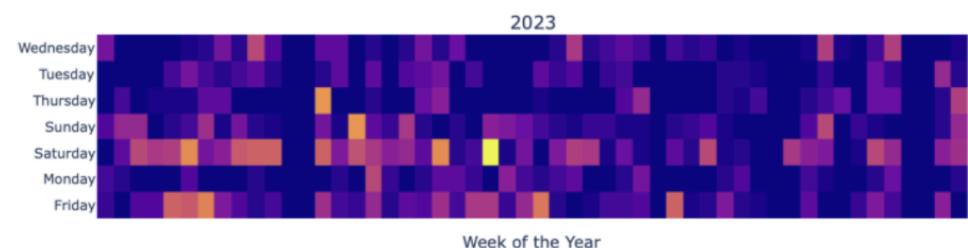
Приложение 2.1. пример вывода матрицы для первого квартала 2023.

Приложение 3:

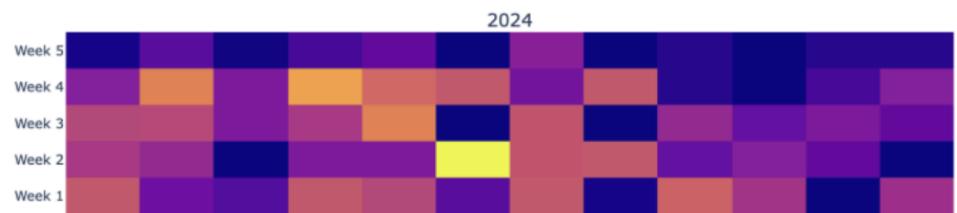
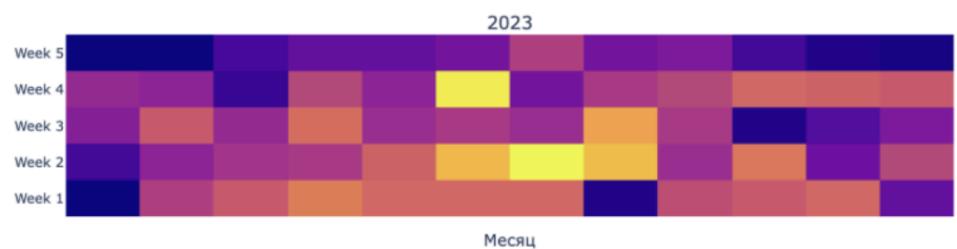
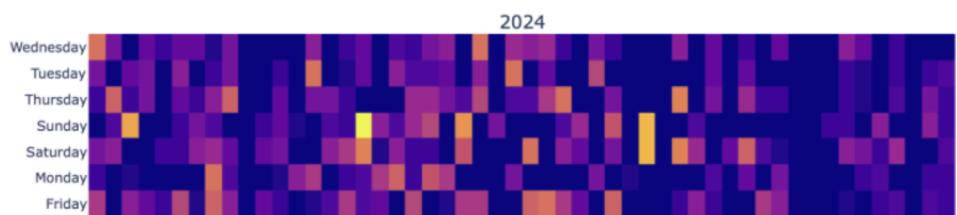
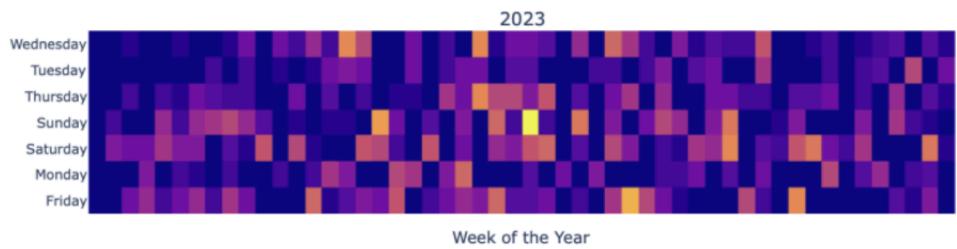




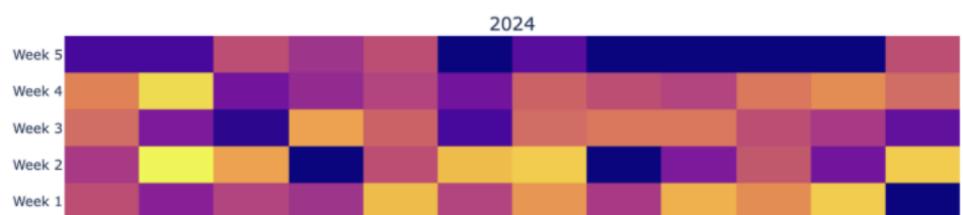
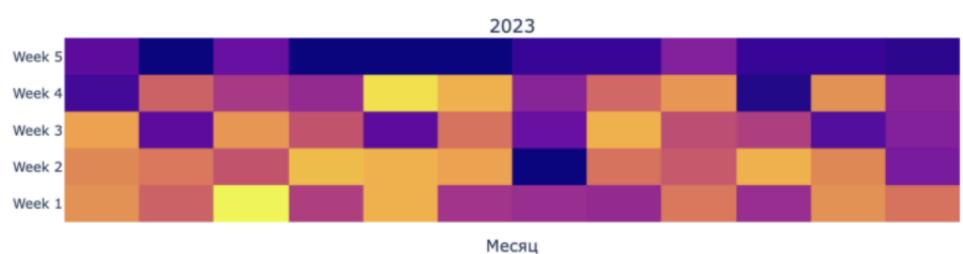
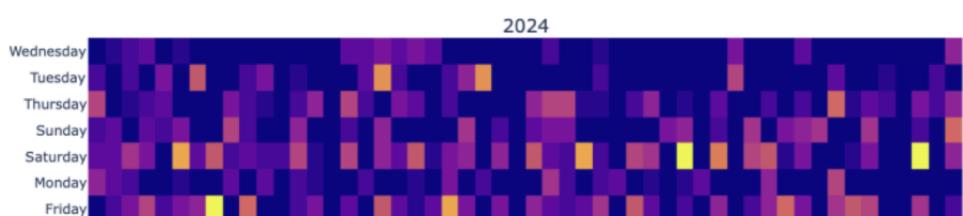
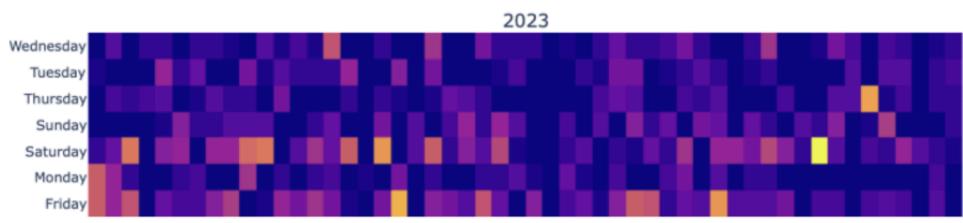
Приложение 3.1. тепловые карты по неделям с детализированием на дни и тепловая карта в месяцах с детализированием на неделю товара 03



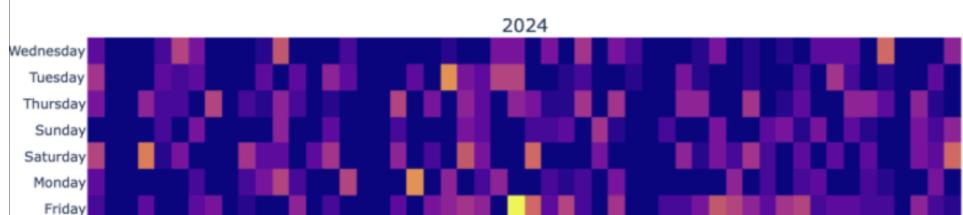
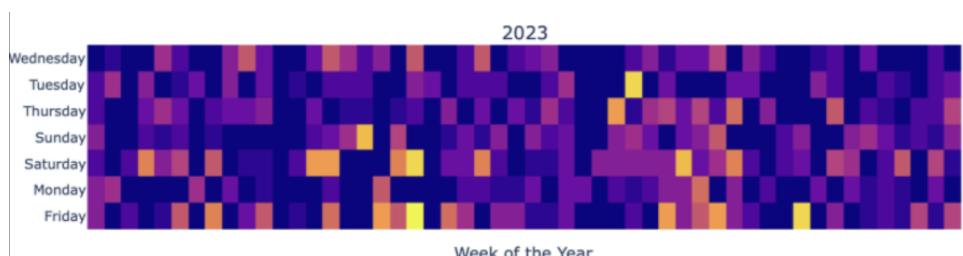
Приложение 3.2. тепловые карты по неделям с детализированием на дни и тепловая карта в месяцах с детализированием на неделю товара 14

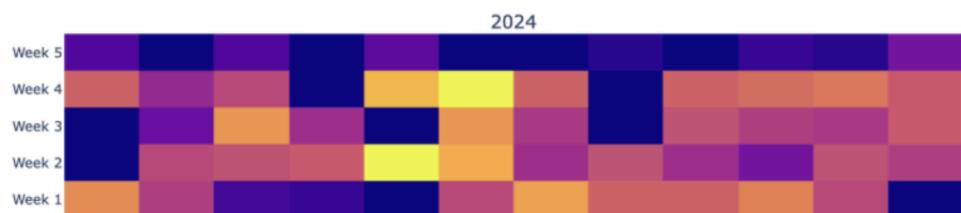
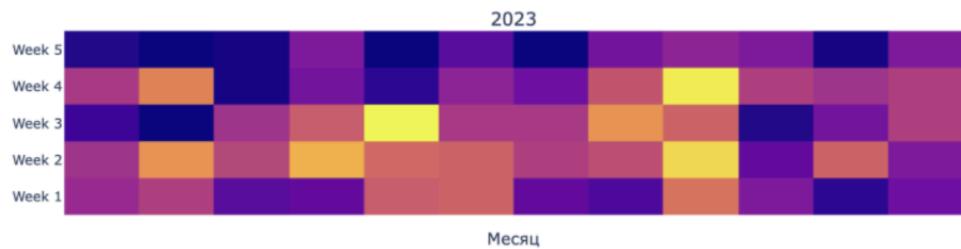


Приложение 3.3. тепловые карты по неделям с детализированием на дни и тепловая карта в месяцах с детализированием на неделю товара 25

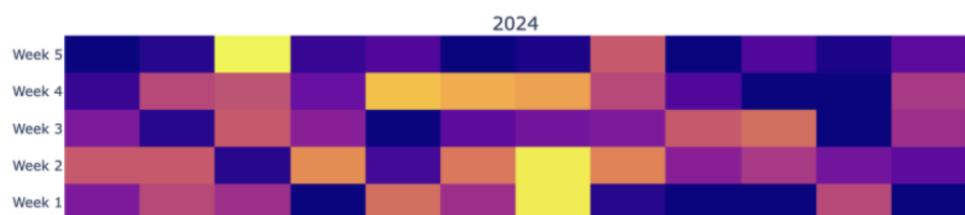
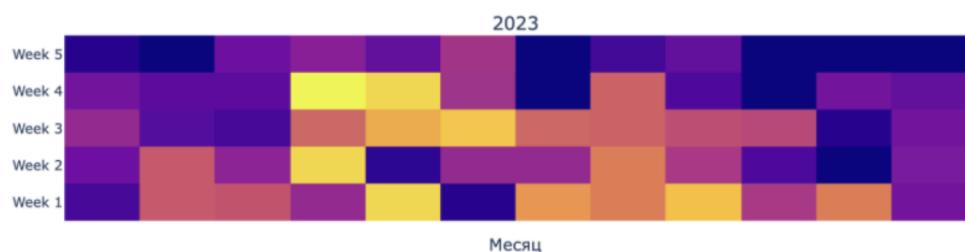
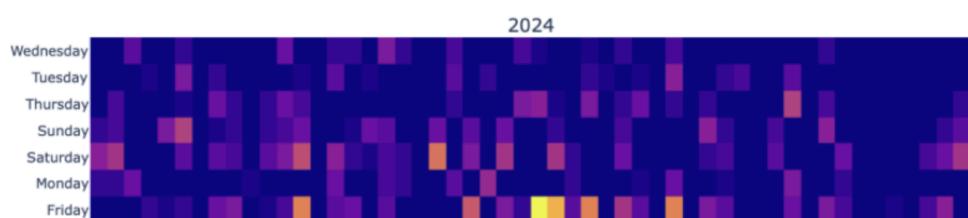
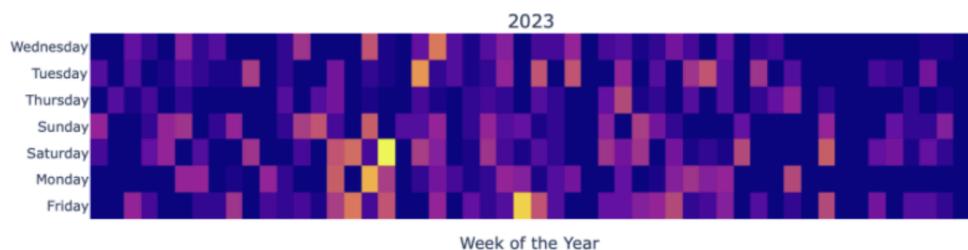


Приложение 3.4. тепловые карты по неделям с детализированием на дни и тепловая карта в месяцах с детализированием на неделю товара 3333333333754

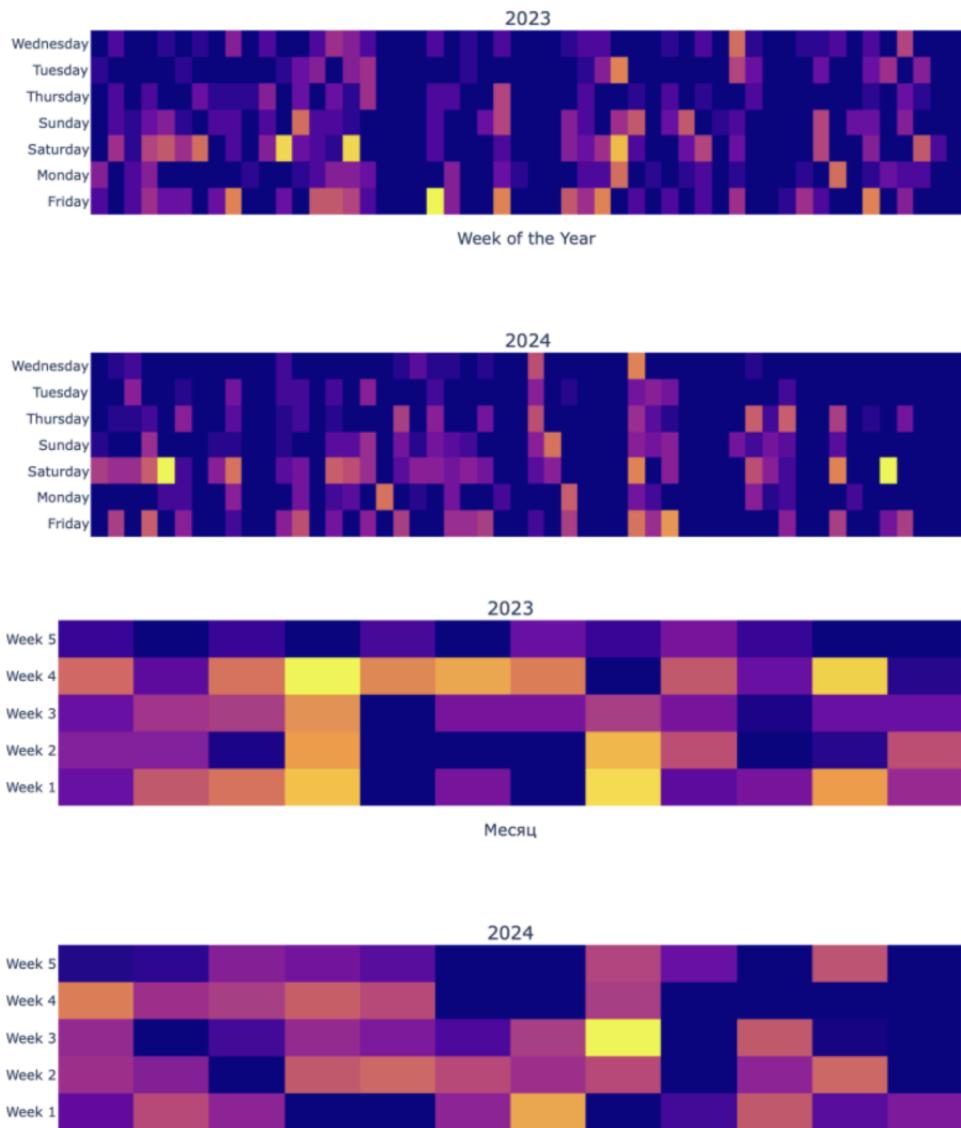




Приложение 3.5. тепловые карты по неделям с детализированием на дни и тепловая карта в месяцах с детализированием на неделю товара 3333333333773



Приложение 3.6. тепловые карты по неделям с детализированием на дни и тепловая карта в месяцах с детализированием на неделю товара 3333333333917



Приложение 3.7. тепловые карты по неделям с детализированием на дни и тепловая карта в месяцах с детализированием на неделю товара 54

Приложение 4: Out-of-Stock Анализ

Товар 25

- 1–13 января — товара не было
- 29 января – 1 февраля — ожидание поставки
- 23–28 марта — ожидание поставки
- 30 апреля – 4 мая — ожидание поставки
- 19–25 мая — ожидание поставки

- 17–20 июня — ожидание поставки
- 18–22 июля — ожидание поставки
- 2–7 августа — ожидание поставки
- 15–17 октября — ожидание поставки
- 12–17 ноября — ожидание поставки
- 30 ноября – 5 декабря — ожидание поставки
- 7–9 января — ожидание поставки
- 3–14 марта — ожидание поставки
- 6–10 апреля — ожидание поставки
- 1–5 июня — ожидание поставки
- 15–22 июня — ожидание поставки
- 28 июня – 2 июля — ожидание поставки
- 7–8 июля — ожидание поставки
- 13–16 июля — ожидание поставки
- 22–25 июля — ожидание поставки
- 13–21 августа — ожидание поставки
- 26 августа – 3 сентября — ожидание поставки
- 8–10 сентября — ожидание поставки
- 21–26 сентября — ожидание поставки
- 6–8 октября — ожидание поставки
- 20 октября – 7 ноября — ожидание поставки
- 8–10 декабря — ожидание поставки

Товар 333333333773

- 12–19 января — ожидание поставки
- 15–21 февраля — ожидание поставки
- 3–7 марта — ожидание поставки

- 19–27 марта — ожидание поставки
- 6–9 мая — ожидание поставки
- 24–30 мая — ожидание поставки
- 25 июля – 1 августа — ожидание поставки
- 2–6 ноября — ожидание поставки
- 11–13 декабря — ожидание поставки
- 7–24 января — ожидание поставки
- 24–27 февраля — ожидание поставки
- 30 марта – 2 апреля — ожидание поставки
- 18 апреля – 7 мая — ожидание поставки
- 15–21 мая — ожидание поставки
- 1–3 июня — ожидание поставки
- 20–24 июня — ожидание поставки
- 29 июня – 3 июля — ожидание поставки
- 27–30 июля — ожидание поставки
- 15–20 августа — ожидание поставки
- 30 ноября – 11 декабря — ожидание поставки

Товар 3333333333754

- 27–30 января — ожидание поставки
- 25 апреля – 2 мая — ожидание поставки
- 13–16 мая — ожидание поставки
- 8–14 июня — ожидание поставки
- 25–26 сентября — ожидание поставки
- 22–25 октября — ожидание поставки
- 10–13 декабря — ожидание поставки
- 18–20 февраля — ожидание поставки

- 17–19 марта — ожидание поставки
- 7–16 апреля — ожидание поставки
- 26–29 апреля — ожидание поставки
- 19–21 мая — ожидание поставки
- 12–20 июня — ожидание поставки
- 25–27 августа — ожидание поставки
- 10–17 сентября — ожидание поставки
- 26 сентября – 1 октября — ожидание поставки
- 13–15 октября — ожидание поставки
- 28–29 октября — ожидание поставки
- 9–13 ноября — ожидание поставки
- 29 ноября – 11 декабря — ожидание поставки
- 20–24 декабря — ожидание поставки

Товар 14

- 20 марта – 3 апреля — ожидание поставки
- 17–20 апреля — ожидание поставки
- 11–15 июня — ожидание поставки
- 21–29 августа — ожидание поставки
- 7–20 октября — ожидание поставки
- 10–16 ноября — ожидание поставки
- 3–18 декабря — ожидание поставки
- 23 января – 2 февраля — ожидание поставки
- 4–16 марта — ожидание поставки
- 30 марта – 4 апреля — ожидание поставки
- 22–24 апреля — ожидание поставки
- 26–28 мая — ожидание поставки

- 7–12 июля — ожидание поставки
- 15–25 августа — ожидание поставки
- 12–19 сентября — ожидание поставки
- 6–11 октября — ожидание поставки
- 27 октября – 7 ноября — ожидание поставки
- 12–20 ноября — ожидание поставки
- 26–30 декабря — ожидание поставки

Товар 333333333917

- 13–14 января — ожидание поставки
- 1–3 февраля — ожидание поставки
- 17–20 апреля — ожидание поставки
- 7–13 мая — ожидание поставки
- 1–4 июня — ожидание поставки
- 20–22 июля — ожидание поставки
- 24–26 сентября — ожидание поставки
- 7–10 октября — ожидание поставки
- 21 октября – 1 ноября — ожидание поставки
- 6–20 ноября — ожидание поставки
- 25–30 декабря — ожидание поставки
- 12–19 февраля — ожидание поставки
- 5–7 марта — ожидание поставки
- 1–7 апреля — ожидание поставки
- 24–26 апреля — ожидание поставки
- 12–24 мая — ожидание поставки
- 31 мая – 6 июня — ожидание поставки
- 12–15 июня — ожидание поставки

- 29 июня – 2 июля — ожидание поставки
- 6–10 июля — ожидание поставки
- 31 июля – 3 августа — ожидание поставки
- 17–20 августа — ожидание поставки
- 31 августа – 10 сентября — ожидание поставки
- 25 сентября – 8 октября — ожидание поставки
- 19–22 октября — ожидание поставки
- 1–10 декабря — ожидание поставки

Товар 54

- 7–10 января — ожидание поставки
- 10–14 марта — ожидание поставки
- 29 апреля – 23 мая — ожидание поставки
- 8–17 июня — ожидание поставки
- 27 июня – 18 июля — ожидание поставки
- 9–11 августа — ожидание поставки
- 22–29 августа — ожидание поставки
- 17–20 сентября — ожидание поставки
- 6–19 октября — ожидание поставки
- 9–18 ноября — ожидание поставки
- 29 ноября – 1 декабря — ожидание поставки
- 17 декабря – 6 января — ожидание поставки
- 30 января – 2 февраля — ожидание поставки
- 11–23 февраля — ожидание поставки
- 4–17 марта — ожидание поставки
- 31 марта – 6 апреля — ожидание поставки
- 30 апреля – 7 мая — ожидание поставки

- 3–5 июня — ожидание поставки
- 18 июня – 1 июля — ожидание поставки
- 8–12 июня — ожидание поставки
- 20 июля – 6 августа — ожидание поставки
- 2–18 сентября — ожидание поставки
- 21 октября – 6 ноября — ожидание поставки
- 12–20 ноября — ожидание поставки
- С 6 декабря — отсутствовал

Товар 03

- 7–15 февраля — ожидание поставки
- 18–23 мая — ожидание поставки
- 7–18 июля — ожидание поставки
- 9–11 августа — ожидание поставки
- 16–19 октября — ожидание поставки
- 18 ноября – 1 декабря — ожидание поставки
- 14–18 января — ожидание поставки
- 19–23 февраля — ожидание поставки
- 14–16 марта — ожидание поставки
- 8–17 апреля — ожидание поставки
- 29 апреля – 7 мая — ожидание поставки
- 11–21 мая — ожидание поставки
- 9–14 мая — ожидание поставки
- 26 июня – 1 июля — ожидание поставки
- 9–12 июля — ожидание поставки
- 31 июля – 6 августа — ожидание поставки
- 24 августа – 18 сентября — ожидание поставки
- 28 октября – 6 ноября — ожидание поставки